

Face Without Organs: 실시간 인터랙티브 디지털 휴먼 모노드라마

Face Without Organs: Real-time Interactive Digital Human Monodrama

요약문

Face Without Organs는 LLM-MetaHuman 파이프라인 위에 감정 표현과 시간적 리듬을 함께 조율해 디지털 휴먼과 사용자 사이의 몰입감 있는 실시간 대화를 구현한 인터랙티브 설치 작품이다. 이를 위해 언어 모델(LLM)를 비롯한 여러 시스템을 통합한 파이프라인 설계와 함께 시간적·비언어적 단서를 함께 다루는 설계 방식인 Real-Presence Orchestration(RPO)를 제안한다. 작품에서 디지털 휴먼은 서비스 도구 차원을 넘어 관람자의 시선과 존재 방식을 되비추는 디지털 타자(digital other)로 설정되며, 한 턴의 대화가 짧은 모노드라마처럼 느껴지도록 연출된다.

주제어

디지털 휴먼, 인터랙티브 아트, MetaHuman, Real-Presence Orchestration(RPO)

1 서론

최근 생성형 인공지능이 일상으로 들어오면서 텍스트 기반 챗봇을 넘어, 실제 사람과 유사한 외형을 갖는 디지털 휴먼 형태의 인터페이스로 확장되고 있다. 그러나 시각적 리얼리즘의 향상에도 불구하고, 응답 지연이나 감정의 표현의 불일치 등 시간적·비언어적 단서가 어긋날 때 발생하는 언캐니한 현상은 여전히 존재한다. 본 연구는 이를 해결하기 위해 LLM-MetaHuman 파이프라인 기반의 감정 및 타이밍 제어를 통합한 RPO(Real-Presence Orchestration)의 설계 원칙과 구현 방안을 기술한다.




그림 1. Face Without Organs

2 시스템·작품 설계

2.1 작품 개요 및 전시 구성




그림 2. 관람 시나리오

본 작품은 디지털 휴먼 페르소나와의 1:1 대면 상황을 통해 '디지털 타자'를 마주하는 경험을 설계한다. 전시 공간 내 대형 디스플레이에 과잉근접된 리얼한 디지털 휴먼은 눈을 감고 있는 idle 상태에 머문다. 관람자가 다가와 1.5-2 m 거리에서 말을 걸면 음성 입력이 감지되어 시스템은 대화 턴으로 인식하고, 눈을 뜨며 대화 상태로 전환한다. 전체 인터랙션은 '각성-응시-대화-침잠'의 사이클로 구성된다.

2.2 시스템 구현 개요




그림 3. LLM-MetaHuman pipeline

본 시스템은 사용자의 음성 또는 텍스트 입력을 시작으로 LLM, TTS를 거쳐 Unreal Engine 5 기반의 MetaHuman 출력으로 이어지는 실시간 파이프라인으로 구현하였다. 수집된 입력 데이터는 로컬 STT 서버에서 텍스트 및 타임스탬프로 변환되어 Websocket 기반의 LLM 어댑터로 전달된다. 구현의 핵심은 RPO 설계를 위한 데이터 전송에 있으며, 대화 턴마다 감정 정보

(mood, intensity)를 담은 단일 JSON 헤더를 선행 전송한 뒤 LLM 응답 텍스트를 짧은 청크(chunk) 단위로 후행 스트리밍하는 방식을 채택하였다. 이를 통해 Unreal Engine은 LLM 어댑터로부터 받은 순차적 단서를 바탕으로 자막, 발화, 표정 등의 출력을 실시간으로 트리거한다. 언어 모델의 경우 인터넷 운용 환경을 고려하여 로컬/클라우드로 전환 가능한 모듈로 구현하였다.

2.3 오케스트레이션 레이어

(1) Emotion system: Expr 선반영과 표정 안정화

Emotion system은 LLM이 반환하는 감정 정보를 자막/발화 확정 이전에 선반영하여, 관람자가 ‘감정이 드러난 얼굴’을 먼저 체감하도록 구성하였다. 감정 정보는 {"mood": "...", "intensity": "..."} 형태의 단일 JSON 헤더로 1회 전송되어 Unreal에서 이를 수신하여 즉시 표정 파라미터를 갱신한다. 이때 핵심은 감정이 즉시 보이되, 급격하게 튀지 않도록 (a) 강도를 정규화하고, (b) 시간적으로 완만하게 변화시키는 것이다. 이를 위해 intensity는 0.0~1.0 범위로 클램프하여 스케일 값을 안정화하고, 이 값을 상안면(눈·눈썹 주변)과 하안면(입꼬리·볼 주변)의 강도를 조절하는 스케일 값이 된다. 표정 상태 변수는 Anim Blueprint(ABP) 내부에서 보간 기반 스무딩(FInterpTo)으로 목표값에 수렴하도록 구성하였다. 따라서 관람자는 텍스트가 완성되기 전에, 그리고 발화하기 전부터 이미 얼굴에서 감정 단서가 나타나는 과정을 경험하고, 이후 자막-발화-립싱크로 이어지는 흐름이 끊기지 않도록 자연스럽게 연결된다.

표 1. Emotion 파라미터 설계(정규화·스무딩·스케일링)

단계	입력/변수	구현	설정 값	의도
1	Expr 헤더	JSON 헤더 1회 수신	mood = [happy,sad,angry,surprised, nervous,neutral] intensity = [0, 1]	표정 선반영
2	Intensity 정규화	Clamp(Float)	Min=0.0 / Max=1.0	표정 스케일 안정화
3	mood 가중치 생성	(Mood_X_ABP × Mood_X_Gain) → Clamp	Clamp 0.1	mood별 정도 1차 정규화
4	스무딩(smoothing)	FInterpTo (Current, Target, DeltaTime, InterpSpeed)	InterpSpeed = 12.0	필·역제, 완만한 수렴
5	커브 스케일링	Multiply + Clamp	예) MouthCornerUp L/R 0.8 계수 × Clamp 0.1	과장 방지 (근육군별 세부 조정)
6	출력	Modify Curves	(0.1 기반 커브 생성)	MetalKamen 얼굴 커브에 할당

표 1은 Expr 기반 표정 제어를 ‘감정 추론’에서 파라미터화된 안정화 문제로 다루기 위한 구성요소를 요약한다. 첫째, intensity를 0~1 범위로 정규화하여 표정 강도를 안전 범위 안에서 유지되도록 했다. 둘째, 표정 상태를 FInterpTo 기반 스무딩(InterpSpeed=12.0)으로 수렴하도록 하여, 다음 표정으로 즉시 점프하지 않도록 하였다. 셋째, 세부 근육군의 커브 스케일링을 통해 보정하였다. 이러한 단계들로 Expr를 선반영하면서도, 관람 경험에서 몰입감을 이어갈 수 있도록 구현하였다.





그림 4. Emotion System

그림 4는 표 1에서 설계한 단계에 따라 출력된 Emotion System의 표정과 표정 전이 상태의 예시이다. mood/intensity는 각각의 강도가 부여된 표정들이며, blend transition은 Sad → Angry 전이처럼 감정 범주가 바뀌는 경우에도 출력은 단절적으로 끊기기보다 이전 상태와 자연스럽게 섞이는 것을 보여준다.



그림 5. 정규화·스케일링 구현 발췌(ABP)

그림 5는 표 1의 과정 중 ABP 내부에서 emotion 파라미터가 생성·정규화·보정되는 단계의 일부를 발췌한 것이다. (a)에서는 mood 관련 변수(Mood_X_ABP)와 Gain을 곱한 뒤, Clamp(0~1)로 정규화하여 상태 변수(M_X)를 갱신하는 과정이며 (b)에서는 근육군별로 세부 스케일 계수를 적용하여 특정 근육이 과도하게 튀는 것을 억제하는 보정을 수행하였다.

(2) Micro-idle: 정지 회피와 발화 집중

Micro-idle은 디지털 휴면이 발화하지 않는 상태에서 정지한 오브젝트처럼 보이지 않도록 하는 생체 신호 단서 층이다. Idle과 Listening 상태에서 낮은 강도의

blink와 미세한 head motion을 유지하여 ‘경청하는 얼굴’ 혹은 ‘살아있는 얼굴’의 인상을 만든다.

(3) Synthesis gate: Final 기반 발화와 립싱크

Synthesis gate는 LLM의 청크 단위로 도착하는 텍스트를 음성으로 변환할 때 끌릴 수 있는 가능성을 피하고, 대화의 한 턴을 관람자가 체감할 수 있도록 구현한 제어 방식이다. 본 프로토타입에서는 음성으로 합성되는 트리거를 Final(문장 확정) 이벤트에 결합했다. Chunk는 자막으로 실시간 누적되도록 하여 진행감을 제공하고, Final이 도착하여 확정되는 순간 SetFinal로 텍스트가 정리되면서 TTS가 시작되도록 하였다. 이 구조는 관람자가 던지는 말에 즉각 대답하지 않고 짧은 공백을 남겨 생각하고 말하는 듯한 시간적 틈이 지각되도록 한다.

또한 생성된 PCM 오디오는 OVRipSync를 기반으로 viseme를 산출하여 입모양을 갱신하도록 하였으며, 10ms 간격(TimerInterval = 0.01s)으로 샘플을 공급하고(BufferSize = 1024) 발화 동안 지속적으로 업데이트 되도록 하였다. 결과적으로 문장 확정(Final)-음성 생성(TTS)-입모양 갱신으로 이어지는 이벤트는 관람자로 하여금 발화가 시작하는 지점부터 얼굴 움직임이 동반되는 하나의 사건으로 경험하도록 한다.



그림 6. blink/emotion/lipsync 곡선 합성

(4) 상태머신(Idle-Listening-Speaking): 턴의 경계

Idle-Listening-Speaking의 세 상태는 전체 상호작용을 단순화한 운용 방식이다. Idle 상태에서는 눈을 감고 미세한 움직임만 유지하며 대기를 하며, 관람자의 발화가 감지되거나 텍스트가 입력되면 Listening으로 전환된다. Listening 상태에서는 LLM 스트리밍이 시작되며 Chunk가 자막으로 누적되어 관람자에게 '대화가 진행 중'과 같은 단서를 제공한다. 이후 문장이 확정되면 Speaking 상태로 전환하며 음성 합성이 시작되고 동시에 입모양이 지속적으로 갱신된다. 발화가 종료되면 표정의 강도는 완화되며 시스템은 다시 Idle로 돌아간다. 이와 같은 일련의 상태 전환을 cue 이벤트에 고정하여 전시 환경에서 관람자와 안정적인 한 턴의 리듬(각성-응시-발화-침잠)을 경험할 수 있도록 했다.




그림 7. 상태머신

3 논의 및 결론

3.1 관람자 경험에 대한 논의

본 작품은 관람자가 ‘과잉근접된 얼굴과 마주 선 자신’을 자각하도록 유도하는 경험에 초점을 맞춘다. 관람자는 말을 걸어야만 얼굴이 깨어난다는 구조를 통해 디지털 휴면을 서비스 도구가 아닌 행위에 의해 호출되는 타자(digital other)로 경험하게 된다.

짧은 응답 지연, 표정의 변화, idle-발화 사이의 전환 등은 관람자에게 ‘대화를 기다리는 얼굴’의 인상을 준다. 텍스트 기반 상호작용에서도 ‘상대가 입력 중’과 같은 단서가 대기 시간을 사회적 신호로 재해석한다[1]. 본 작품은 이를 표정·자막·발화 타이밍 등 여러 층의 단서로 확장해 체감 리듬을 형성한다. 동시에 립싱크나 표정의 미세한 불일치 혹은 과장된 얼굴 스케일은 관람자로 하여금 몰입과 후퇴의 경계를 환기하고, 디지털 휴면과 마주하고 있는 관람자 자신을 되돌아보게 될 여지를 남긴다.

3.2 RPO의 HCI 시사점

본 프로토타입은 Real-Presence Orchestration(RPO)을 제안·구현하여, 디지털 휴면 설계에서 시각적 출력 품질만큼이나 표정 선반영의 타이밍과 안정화, 응답 지연, 미세 움직임(idle, blink), 립싱크가 결합된 한 턴의 사건성을 구성하고, 이러한 시간적·비언어적 단서가 경험을 강하게 형성할 수 있음을 보여준다. 다만 본 전시용 프로토타입은 핵심 리듬(턴 구조, 지연·전환·발화) 구현에 초점을 두었으며, 정교한 턴테이킹·백채널·시선 전환 및 사용자 비교 평가 등은 향후 과제로 남는다.

참고 문헌

1. Zainab Iftikhar, Yumeng Ma, Jeff Huang, “Together but not together”: Evaluating Typing Indicators for Interaction-Rich Communication, Proceedings of the 2023 CHI Conference on Human Factors in Computing Systems (CHI '23), Hamburg,

Germany, Article 724, 12 pages, ACM,
2023.

<https://doi.org/10.1145/3544548.3581248>